Introducción Rápida a R

Irán Apolinar Peredo Cortes 18 de julio de 2019

Introducción

A continuación se mostrarán los comando básicos en R necesarios para poder tener un conocimeinto básico del uso de las librerías básicas en cursos introductorios de estadística. Estas notas se desarrollarán mostrando el conjunto de código que se introduce en R así como su respectiva salida, por tal motivo no es necesario para su revisión la instalación y el uso de R, sin embargo en el momento de correr programas si será necesario. Se recomeinda tenerlo instalado y practicar para que la lectura subsecuente sea fluida. Estas notas así como las bases de datos utilizadas estarán disponibles en el siguiente enlace: https://github.com/IranNash/.

En R podemos llamar a librerías con el comando library(), así como instalar paquetes con install.packages(). Para solicitar información de un comando podemos utilizar help(). Podemos introducir conentarios dentro del código anteponiendo un # al comentario sin que afecte la ejecución.

Operaciones Básicas: definimos a = 10, b = 20 y c = 30.

```
a<-10
b<-20
c<-15
```

La asignación de valores en R se da mediante el simbolo <-, tambien puede ser utilizado el simbolo =. La suma, resta multiplización y división utilizan +, -, * y / respectivamente. La jerarquía de operaciones puede ser definitida utilizando parentesis.

```
a+b

## [1] 30

a-b

## [1] -10

a*b

## [1] 200

a/b

## [1] 0.5

a+((b/c)*(c-a))*a

## [1] 76.66667
```

Para imprimir texto en pantalla utilizamos el comando print(), tambien se puede utilizar para mostrar el valor guardado en variables. Podemos concatenar texto con variables con los comandos paste() o conatenar texto con varias variables u operaciones con el comando sprintf()y %s como sigue:

```
print("Hola")
## [1] "Hola"
print(a)
## [1] 10
```

```
print(paste("el dato a vale:", a))

## [1] "el dato a vale: 10"

sprintf("la suma de a + b es %s,y la de a-b es %s",a+b, a-b)
```

```
## [1] "la suma de a + b es 30, y la de a-b es -10"
```

Para introducir **datos boleanos**, es decir, que tienen como salida verdadero o falso utilizamos los operadores <,>,==, >= o <=. Tamien es posible guardar un dato boleano mediante <- y luego imprimirlo en pantalla con print() como sigue:

```
a == 10
## [1] TRUE
b >= 20
## [1] TRUE
c < a
## [1] FALSE
d <- a == 20
print(a)</pre>
```

[1] 10

El **módulo o residuo** de una división se optiene con el comando %%. Para **truncar** a enteros un número se utiliza el comando trunc():

```
a <- 41
a<mark>%%</mark>2
```

```
## [1] 1
```

```
trunc(14.98765)
```

[1] 14

Cuando se realizan programas es común solicitar la introducción de datos desde el teclado y que se almacene en alguna variable. Para poder introducir datos numéricos en R utilizamos el comando scan se debe especificar el número de datos a introducir. Para introducir datos de texto utilizamos junto con scan el comando what y especificamos que el tipo de datos es un character (este ejemplo se recomienda correrlo en su terminal de R).

```
d<-scan(n=1)
print(d)

## numeric(0)
ch<-scan(n=1, what = "character")
print(ch)</pre>
```

character(0)

Las condicionales en R utiliza el comando if(){} y else{}, se establece la condición entre parentesis () y finalmente entre llaves {} se introduce lo que debe de realizarse si se cumple la condición. Por ejemplo, supongamos que a es igual a 10. Si esto se cumple entonces de imprime el texto a es igual a 10. Para este ejemplo utilizamos el operador == que se utiliza para preguntar si una variable es igual a otra, en este caso, si una variable es igual a un número:

```
a <- 10
if (a == 10){
```

```
print("a es igual a 10")
}
```

```
## [1] "a es igual a 10"
```

Hagamos ahora un ejemplo más complejo. Supongamos que a=10 y que b=20 y definamos dos variables auxiliares h=0 y g=0. Preguntemos ahora si a<5 de ser verdad, entonces solicitamos que se realice la operación a*b y que el resultado se guarde en b. De ser falsa la afirmación entonces queremos que se realice una resta b0 y que se guarde en b0. Finalmente queremos que muestre en pantalla el valor final de b1 y b2. El código para este ejemplo es el siguiente:

```
a<-10
b<-20
h<-0
g<-0
if(a>5){
   h<-a*b
}else{
   g<-a-b
}
print(h)</pre>
```

```
## [1] 200
print(g)
```

```
## [1] 0
```

En R se pueden utilizar ttres tipos de ciclos(bucles o loops). Utilizamos el comando while(){} para que un ciclo se repita mientras se cumple una condición. Normalmente este tipo de ciclos utiliza contadores, es decir, variables auxiliares donde especificamos donde empieza a contar el ciclo. Dentro del ciclo generalmente especificamos los incrementos del contador. Finalmente el ciclo se repetirá hasta que el contador cumpla la condición.

Por ejemplo, realicemos un ciclo que permita repetir 8 veces la frase mi primer ciclo en R. El código para este ejemplo es como sigue:

```
i <- 1
while(i <= 8){
  print("mi primer ciclo en R")
  i = i +1
}
## [1] "mi primer ciclo en R"</pre>
```

```
## [1] "mi primer ciclo en R"
```

Si leyeramos el código este diría "definimos un contador i = 1. Mientras el contador i sea menor o igual a 8" entonces imprime mi primer ciclo en R. Ahora suma al contador i una unidad para que en el siguiente ciclo valga 2" y así sucesivamente.

Realicemos el mismo ejemplo con un ciclo for(){}. en este caso definimos dentro de la condición el contador y le decimos el rango que va a recorrer. Finalmente le decimos en que hacer en cada ciclo. el código para realizar el mismo ejercicio es el siguiente:

```
for(i in 1:8){
  print("mi primer ciclo en R")
}
## [1] "mi primer ciclo en R"
```

Como podemos ver el código es más simple. Tenemos un contador i que va a recorrer de 1 a 8, es decir, ocho veces se repetirá la instrucción print ("mi primer ciclo en R") se sabe que son 8 porqué se a espesificado con el código in 1:8 para comprobarlo basta con imprimir i en pantalla

```
print(i)
```

[1] 8

Vectores y Matrices

Podemos crear un vector con el comando c() y asignarlo a una variable. Podemos hacer una secuencia de numeros dentro de un vector utilizando la nomenclatura c(j:k) para que el vector tome los valores de j hastak. Tambien es posible crear un vector de ceros con el comando numeric() especificando el número de ceros, es decir el tamaño del vector:

```
x < -c(1,2,3,4,5)
print(x)
## [1] 1 2 3 4 5
x < -c(5:10)
print(x)
## [1] 5
          6 7
                 8 9 10
x<- numeric(5)
print(x)
```

[1] 0 0 0 0 0

Para buscar un dato específico dentro del vector utilizamos la nomenclatura x[i] donde i es la posición del elemento que buscamos. Podemo extraer más de un nímero con el comando c(i,j,k) donde i, j, k nos muestran la posición de los datos a extraer:

```
x < -c(3,4,5,6,7,8,9,10,11)
print(x)
## [1]
       3 4 5 6 7 8 9 10 11
x[2]
## [1] 4
x[c(2,4,6)]
```

[1] 4 6 8

Podemos realiza operaciones aritméticas con los elementos de un vector como restarle o sumarle un número a cada elemento, multiplicar cada elemento por un número dado o elevar cada elemento a una cierta potencia:

```
x < -c(1,2,3,4,5,6,7,8,9)
print(x)
## [1] 1 2 3 4 5 6 7 8 9
x+5 #resta
## [1] 6 7 8 9 10 11 12 13 14
x-3 #suma
## [1] -2 -1 0 1 2 3 4 5 6
x*2 #multiplicación
## [1] 2 4 6 8 10 12 14 16 18
x^2 #potencia
## [1] 1 4 9 16 25 36 49 64 81
Estas mismas operaciones pueden realizarse entre vectores, por ejemplo:
x < -c(1,2,3,4,5,6,7,8,9)
y < -c(3,4,5,6,7,8,9,10,11)
## [1] 4 6 8 10 12 14 16 18 20
х-у
## [1] -2 -2 -2 -2 -2 -2 -2 -2
x*y
## [1] 3 8 15 24 35 48 63 80 99
x^y
## [1]
                              16
                                          243
                                                      4096
                                                                 78125
                                                                            1679616
## [7]
          40353607
                    1073741824 31381059609
Podemos tambien crear vectores de caracteres, por ejemplo, supongamos que queremos introducir en un
vector el genero de 9 personas, bastaría con introducir entre comillas " " el caracter correspondiente.
sexo <- c("hombre", "mujer", "mujer", "otro", "hombre", "hombre", "mujer", "mujer", "otro")</pre>
print(sexo)
## [1] "hombre" "mujer"
                          "mujer" "otro"
                                              "hombre" "hombre" "mujer"
## [9] "otro"
En la practica es común preguntarse si la variable es un factor, esto permite crear categorías dentro del vector.
Para esto utilizamos el comando is.factor() para comprobar si es factor y as.factor() para transformar.
is.factor(sexo)
## [1] FALSE
sexo<-as.factor(sexo)</pre>
is.factor(sexo)
```

[1] TRUE

Como vemos en la primera salida is.factor(sexo) muestra un FALSE lo que significa que no es un factor, es decir, el vector no tiene categorías. Posteriormente con el comando as.factor(sexo) se vuelve a guardar en sexo con lo cual remplazamos la variable original por la variable con factores. Ahora si mandamos a imprimir sexo tenemos:

```
print(sexo)
```

```
## [1] hombre mujer mujer otro hombre hombre mujer mujer otro
## Levels: hombre mujer otro
```

nos muestra los tres niveles. Esto será importante cuando se trabaje con variables categóricas. Podemos generar una **matriz** a partir de combinación de varios vectores o contruirla directamente. Para el primer caso. Supongamos que creamos un vector con las estaturas de 9 personas, como en el caso anterior:

```
est<-c(1.85, 1.64, 1.56, 1.71, 1.79, 1.81, 1.56, 1.63, 1.69)
print(est)
```

```
## [1] 1.85 1.64 1.56 1.71 1.79 1.81 1.56 1.63 1.69
```

Con el comado rbind() podemos combinar dos vectores y ordenarlos como filas. Con el comando cbind() hacemos los mismo pero lo ordenamos como columnas.

```
A<-cbind(sexo, est)
print(A)
```

```
##
         sexo
               est
##
    [1,]
             1 1.85
##
    [2,]
             2 1.64
    [3,]
            2 1.56
##
##
   [4,]
            3 1.71
   [5,]
             1 1.79
             1 1.81
##
    [6,]
##
    [7,]
            2 1.56
##
   [8,]
            2 1.63
   [9,]
             3 1.69
##
B<-rbind(sexo, est)
print(B)
```

```
## [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## sexo 1.00 2.00 2.00 3.00 1.00 1.00 2.00 2.00 3.00
## est 1.85 1.64 1.56 1.71 1.79 1.81 1.56 1.63 1.69
```

Como puede observarse la variable sexo ha sido remplazada por numero del 1 al 3, esto significa que se ha asignado la categoría correspondiente. Esto es útil en el momento de hacer modelos o gráficos.

Para hacer una matriz directamente utilizamos el comando matrix() en el cual establecemos el número de filas nrow y el número de columnas ncol los datos de la matriz se introducen como si fuera un vector. La dimensión de la matriz se muestra con el comando dim()

```
A <- matrix(c(1,2,3,4,5,6), nrow = 2, ncol = 3)
print(A)

## [,1] [,2] [,3]
## [1,] 1 3 5
## [2,] 2 4 6

dim(A)
```

```
## [1] 2 3
```

Las operaciones operaciones elementales con matrices se realizan de la siguiente forma:

```
A \leftarrow matrix(c(1,2,3,4), nrow = 2, ncol = 2)
B \leftarrow matrix(c(10,11,12,13), nrow = 2, ncol = 2)
t(A) #Transpuesta
##
        [,1] [,2]
## [1,]
           1
                 2
## [2,]
           3
                 4
A*3 #Multiplicación Escalar
##
        [,1] [,2]
## [1,]
           3
                9
## [2,]
           6
               12
A+B #Suma de matrices
##
        [,1] [,2]
## [1,]
          11
               15
## [2,]
          13
               17
A-B #Resta de matrices
##
        [,1] [,2]
## [1,]
          -9
               -9
## [2,]
                -9
          -9
A%*%B #Producto Matricial
        [,1] [,2]
##
## [1,]
          43
               51
## [2,]
          64
                76
solve(A) #Matriz Inversa
##
        [,1] [,2]
          -2 1.5
## [1,]
## [2,]
           1 -0.5
```

La matriz identidad se logra con el comando diag() donde especificamos el tamaño de la matriz. Por ejemplo una matriz identidad de 5x5 se realiza como:

diag(5)

```
[,1] [,2] [,3] [,4] [,5]
##
## [1,]
            1
                  0
                       0
                             0
                                   0
## [2,]
            0
                       0
                             0
                                   0
                  1
## [3,]
                                   0
            0
                  0
                       1
                             0
## [4,]
            0
                  0
                       0
                             1
                                   0
## [5,]
            0
                       0
                                   1
```

Dataframe

Un data frame es un arreglo rectangular que permite almacenar distintos tipos de datos, tanto numéricos como de caracter. Una forma sencilla de hacerlo es a partir de vectores, por ejemplo:

```
sexo <- c("hombre", "mujer", "mujer", "otro", "hombre", "hombre", "mujer", "mujer", "otro")
est<-c(1.85, 1.64, 1.56, 1.71, 1.79, 1.81, 1.56, 1.63, 1.69)
edad <- c(18, 20, 23, 25, 22, 18, 17, 19, 20)</pre>
```

```
data <- data.frame(sexo, est, edad)
print(data)</pre>
```

```
##
       sexo est edad
## 1 hombre 1.85
## 2
      mujer 1.64
                    20
## 3
      mujer 1.56
                    23
## 4
       otro 1.71
                    25
## 5 hombre 1.79
                    22
## 6 hombre 1.81
                    18
## 7
      mujer 1.56
                    17
## 8
      mujer 1.63
                    19
## 9
       otro 1.69
                    20
```

La estructura de los datos se obtiene con el comando str():

```
str(data)
```

```
## 'data.frame': 9 obs. of 3 variables:
## $ sexo: Factor w/ 3 levels "hombre", "mujer",..: 1 2 2 3 1 1 2 2 3
## $ est : num 1.85 1.64 1.56 1.71 1.79 1.81 1.56 1.63 1.69
## $ edad: num 18 20 23 25 22 18 17 19 20
```

Las estadísticas básicas del dataframe se obtiene con el comando summary():

summary(data)

```
##
        sexo
                     est
                                       edad
##
    hombre:3
                       :1.560
                                 Min.
                                         :17.00
                Min.
##
    mujer:4
                1st Qu.:1.630
                                 1st Qu.:18.00
                Median :1.690
                                 Median :20.00
##
    otro :2
##
                Mean
                       :1.693
                                 Mean
                                         :20.22
##
                3rd Qu.:1.790
                                 3rd Qu.:22.00
##
                Max.
                       :1.850
                                 Max.
                                         :25.00
```

Podemos guardar los datos en formato .txt con el comando write.table. Se debe especificar el nombre del archivo así como el tipo de separación de los datos y si tiene o no encabezado entre otras definiciones, como sigue:

```
write.table(data, file = "data.txt", sep = ",", col.names = TRUE)
```

Para poder llamar una base de datos podemo utilizar read.table() si es en formato .txt. Podemos llamar un .csv con read.csv(). Recordemos que para tener todas las especificaciones del comando basta con teclear help("read.csv") para tener todas las funciones.

```
data<-read.table("data.txt", header = TRUE, sep = ",")
help("read.csv")</pre>
```

Para llamar una variable específica dentro del data.frame utilizamos el simbolo \$ después del nombre del data.frame.

```
data$sexo
```

```
## [1] hombre mujer mujer otro hombre hombre mujer mujer otro
## Levels: hombre mujer otro
summary(data$est)
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
```

```
## 1.560 1.630 1.690 1.693 1.790 1.850
```

Finalmente, cuando se trabajan con bases de datos con muchas variables, puede llegar a ser complicado utilizar el simbolo \$ anteponiendolo al nombre de la base para llamar variables. En su lugar podemos utilizar el comando attach()


```
attach(data)
## The following objects are masked _by_ .GlobalEnv:
##
       edad, est, sexo
##
summary(est)
##
      Min. 1st Qu.
                      Median
                                 Mean 3rd Qu.
                                                  Max.
##
     1.560
              1.630
                       1.690
                                1.693
                                        1.790
                                                 1.850
Para regresar a la forma de llamar los datos originalmente con $ utilizamos detach()
detach(data)
```

Gráficos básicos

En R existen muchas posibilidades de hacer gráficos, podemos utilizar los gráficos nativos de R o utilizar librerías como ggplot2. Para esta introducción rápida vamos a mostrar los gráficos nativos de R.

El gráfico de dispersión puede realizarse cimplemente dando dos variables con la función plot(), por ejemplo: attach(data)


```
## The following objects are masked _by_ .GlobalEnv:
##
## edad, est, sexo
plot(est, edad)
```




Podemos darle formato a los gráficos nativos en R de la siguiente forma:

```
plot(est, edad,
    type = "p",
    pch = 10,
    col = "blue",
    main = "Título del gráfico",
    sub= "Subtitulo del Gráfico",
    xlab = "nombre de la variable x",
    ylab = "nombre de la variable y")
```

iliulo uel granco




mətoyrama



Para utilizar el gráfico de barras o el gráfico de pastel se realiza una tabla con el comando table() ya que se trata de datos categóricos.

```
#Gráfico de barras
barplot(table(sexo),
    main = "Título del gráfico",
    sub= "Subtitulo del Gráfico",
    xlab = "nombre de la variable x",
    ylab = "nombre de la variable y")
```

TILUIO UEI GIAIICO




nombre de la variable x Subtitulo del Gráfico

```
#Gráfico de pastel
pie(table(sexo),
    main = "Título del gráfico",
    sub= "Subtitulo del Gráfico",
    xlab = "nombre de la variable x",
    ylab = "nombre de la variable y")
```

iliulo uel granco


nombre de la variable y



nombre de la variable x Subtitulo del Gráfico

Para realizar un el gráfico de cajas, enfrentamos una variable categórica contra una variable continua, es por eso que se expresa como un modelo, es decir, utilizamos el simbolo \sim .


TILLIO UCI GIAIICO



Para hacer gráficos de lineas podemo utilizar tambien la función plot(). Con el comando rnorm() podemos generar numeros aleatorios basados en la distribución normal.

```
x<-rnorm(50, 0, 1) #media 0, varianza 1
plot(x,
    type = "l",
    col = "blue",
    main = "Título del gráfico",
    sub= "Subtitulo del Gráfico",
    xlab = "nombre de la variable x",
    ylab = "nombre de la variable y")</pre>
```

TILUIO UEI GIAIICO



Aplicación: Calculo de mínimos cuadrados ordinarios

Apliquemos parte de los aprendido, realicemos el calculo de regresión lineal mediante un modelo por aproximación de mínimos cuadrados ordinarios $\mathbf{y} = \theta \mathbf{x} + \epsilon$. Este modelo se basa en aproximar una variable minimizando el error cuadrático. primero definamos la matriz de coeficientes:

```
x <-c(600, 600, 700, 700, 700, 900, 950, 950) #variable independiente
i <-c(1,1,1,1,1,1,1,1)
X <-cbind(i,x) #Matriz de coeficientes
print(X)

## i x
## [1,] 1 600
## [2,] 1 600
## [3,] 1 700
## [4,] 1 700
## [5,] 1 700
## [6,] 1 900
## [7,] 1 950
## [8,] 1 950

y <-c(40, 44, 48, 46, 50, 48, 46, 45) #variable de respuesta</pre>
```


El vector θ que minimizan el error cuadrático medio se calcula evaluando $\theta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ se calculo así:

```
#Transponer
Xt<-t(X)
#Producto Matricial
B<-Xt%*%X
#Invertir la matriz</pre>
```

```
C<-solve(B)</pre>
#Producto matricial
D<-C%*%Xt
u < -D%*%y
print(u)
##
              [,1]
## i 40.853658537
## x 0.006585366
En la práctica, la solución del modelo de mínimos cuadrados se hace mediante el comando 1m() de la siguiente
manera:
m \leftarrow lm(y~x)
summary(m)
##
## Call:
## lm(formula = y \sim x)
##
## Residuals:
##
       Min
                 1Q Median
                                 ЗQ
                                         Max
## -4.8049 -1.3598 -0.1341 1.5488 4.5366
##
## Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
##
## (Intercept) 40.853659
                            6.156123
                                        6.636 0.000565 ***
                0.006585
                            0.007943
                                      0.829 0.438812
## x
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.115 on 6 degrees of freedom
## Multiple R-squared: 0.1028, Adjusted R-squared: -0.04676
## F-statistic: 0.6873 on 1 and 6 DF, p-value: 0.4388
Para realizar el gráfico utilizamos plot()
plot(x,y, type = "p",
     xlab = "x",
     ylab = "y",
     main="Regresión Lineal Simple")
```

abline(m, col="blue")

negresion Linear Jimpie




Realicemos ahora el mismo ejercicio matricial pero agreguemos un ajuste cuadrático:

[,1] ## i -78.0000 ## x 0.3200 ## x2 -0.0002

La grafica correspondiente se puede hacer mediante el comando curve(). Se espesifica con from = y to = los límites de la curva en el eje de las x. Con add = especificamos si se quiere superponer a la gráfica anterior.:

ivedi esioni eon alaste eaan aneo



Este ajuste cuadrático para este caso es mejor que el ajuste lineal.